

효율적인 Attention 연산을 활용한 교통 예측 문제 해결

[Ref] DSAformer: Deformable Spatial Attention Transformer for Traffic Forecasting, AAAI 2027 Phase 1 (Pass)

충남대학교 데이터 인텔리전스 연구실


박사과정 한승훈

- Introduction
- Methodology
- Experiments
- Conclusions

Introduction


■ Traffic Forecasting

- 정의: 과거의 교통 상태 정보 (교통량, 속도 등) 을 이용하여 미래의 교통 상태를 예측하는 문제




Traffic Forecasting

- Traffic Forecasting 문제가 어려운 이유: **temporal dependency** + **spatial dependency**를 동시에 고려



- 교통 예측을 위한 GNN 기반 방법
 - 그래프 모델링: 교통 네트워크 ↔ 교통 그래프




■ 교통 예측을 위한 GNN 기반 방법

- 한계점: 멀리 떨어진 sensor들 사이의 관계를 모델링하기 어려움 (Global dependency 모델링 문제)
 - GNN으로 해결 시 → Over-smoothing, computational cost 문제 발생



- 교통 예측을 위한 Transformer 기반 방법



- Transformer 장점: self-attention을 통해 모든 노드 사이의 관계를 직접 모델링 가능
 - Global, long-range dependency 모델링 가능




■ 교통 예측을 위한 Transformer 기반 방법

• 한계점

- 모든 노드 쌍을 모델링 하기 때문에 $O(N^2)$ 의 계산 필요
- 불필요한 noisy sensor의 정보까지 모델링



- 교통 예측을 위한 Sparse Attention 기반 방법
 - 모든 노드가 아닌 일부 노드만 선택하여 attention 수행
 - Masking 등을 활용




- 교통 예측을 위한 Sparse Attention 기반 방법


- 한계점: **Spurious Key Attention** Case가 존재

➤ Query sensor와 관계가 약한 sensor가 key sensor로 선택되어 높은 attention을 받는 문제

Existing Sparse Mechanism




Deformable Spatial Attention Mechanism



Methodology


- 제안하는 방법: Deformable Spatial Attention Transformer for Traffic Forecasting (DSAformer)



■ 제안하는 방법: Deformable Spatial Attention Transformer for Traffic Forecasting (DSAformer)

입력 traffic을 어떻게 풍부하게 표현할까?

- 시계열에 다양한 context 추가
 - 시간 정보: Time-of-day, Day-of-week
 - 구조 정보: traffic graph 내 구조적 위치
 - 과거 정보: 지난주 같은 시간대 traffic





■ 제안하는 방법: Deformable Spatial Attention Transformer for Traffic Forecasting (DSAformer)


query sensor에 대하여 어떤 sensor들을 참고할까?

- Deformable Spatial Attention
 - Deformable Sampling
 - Kernel-based Interpolation
 - Sampled Sensor Aggregation

Query Sensor



- 제안하는 방법: Deformable Spatial Attention Transformer for Traffic Forecasting (DSAformer)



시계열 중 어떤 시간 패턴을 참고할까?

- 전체 temporal pattern을 모두 사용하지 않음
 - Temporal convolution을 통해 2가지 표현 생성
 - Local temporal pattern, Temporal gate


가까운 시간 변화 패턴 추출

어떤 패턴이 중요한지 선택


■ 제안하는 방법: Deformable Spatial Attention Transformer for Traffic Forecasting (DSAformer)

여러가지 spatial, temporal 정보를 어떻게 합칠까?

- Geographic branch, Semantic branch, Temporal branch의 중요도가 항상 동일하지 않음
- Gating Mechanism을 통해 branch importance를 반영하여 여러 branch의 표현을 fusion



■ 제안하는 방법: Deformable Spatial Attention Transformer for Traffic Forecasting (DSAformer)



미래 traffic을 어떻게 안정적으로 예측할까?

- 마지막 관측값에서 traffic이 얼마나 변할 것인지 예측
 - *Future Traffic = Last Observation + Predicted Change*
 - 기존 연구들은 미래 traffic state를 직접 예측

Experiments

■ 실험 설정

• 데이터셋

- 총 4개의 교통 데이터셋에서 성능 비교
- PEMS03, PEMS04, PEMS07, PEMS08

Dataset	#Nodes	#Edges	#Timesteps	Interval	Time Range
PEMS03	358	547	26,208	5 min	09/01/2018–11/30/2018
PEMS04	307	340	16,992	5 min	01/01/2018–02/28/2018
PEMS07	883	866	28,224	5 min	05/01/2017–08/31/2017
PEMS08	170	295	17,856	5 min	07/01/2016–08/31/2016

• 평가 지표

- 교통 예측에서 주로 사용되는 MAE, MAPE, RMSE 사용



• Baseline

- (1) GNN 기반
- (2) Transformer 기반 모델
- (3) Sparse Attention 기반 모델

- Main 실험 결과

Model	PEMS03			PEMS04			PEMS07			PEMS08		
	MAE	MAPE(%)	RMSE	MAE	MAPE(%)	RMSE	MAE	MAPE(%)	RMSE	MAE	MAPE(%)	RMSE
STGCN	17.15	16.66	28.98	22.03	14.63	33.84	24.25	10.49	37.01	17.79	11.12	27.04
DCRNN	15.56	15.28	27.48	20.03	13.86	31.83	22.01	9.54	34.63	15.44	9.96	24.34
GWNET	15.02	14.73	25.75	18.90	13.01	30.74	20.26	8.55	33.08	14.20	9.13	23.96
AGCRN	15.21	14.94	26.24	18.89	12.92	30.68	20.38	8.65	33.87	14.98	9.91	23.99
D ² STGNN	<u>14.55</u>	15.24	25.20	<u>18.32</u>	12.91	30.69	20.23	8.72	32.84	13.99	9.50	22.85
SAGCRN	14.74	15.02	25.10	18.55	12.96	30.79	19.83	8.51	32.37	13.57	9.05	22.83
STTN	16.60	16.50	28.90	19.91	13.66	31.66	20.38	9.22	34.50	14.43	9.93	23.12
STAEformer	14.96	15.11	26.33	18.64	<u>12.89</u>	30.36	19.06	7.95	32.76	13.22	8.75	22.87
LHMformer	<u>14.55</u>	14.12	25.50	18.44	13.00	30.71	<u>18.53</u>	<u>7.90</u>	<u>31.88</u>	<u>13.10</u>	<u>8.64</u>	<u>22.81</u>
DTRformer	14.79	14.41	25.22	19.29	12.90	30.68	<u>20.36</u>	<u>8.76</u>	<u>33.10</u>	<u>14.27</u>	<u>9.10</u>	<u>23.02</u>
STWave	14.78	16.62	26.40	19.18	13.26	31.34	19.80	8.64	33.10	13.58	8.99	23.86
PDFormer	14.77	15.52	25.73	18.40	12.96	<u>30.10</u>	19.46	8.23	32.48	13.47	8.86	23.69
MultiSPANS	14.86	15.17	<u>24.76</u>	18.88	13.15	<u>30.12</u>	19.91	8.95	32.55	14.38	9.29	23.47
DSAformer	14.45	<u>14.26</u>	23.37	18.16	12.72	29.89	18.24	7.73	31.34	12.98	8.56	22.66

■ Ablation Study 및 Efficiency Comparison 결과



Conclusions

- 기존 sparse attention 기반의 방법들의 문제점인 **Spurious Key Attention**을 해결하기 위해 DSAformer 제안
- DSAformer
 - **Deformable Spatial Attention**을 통한 교통 상황에 맞는 sensor들을 선택하여 attention에 활용
 - Spurious key attention 해결
 - Sparse attention으로 일부 정보만 사용하는 만큼 input 보강 및 residual prediction 등 추가적인 모듈을 통한 예측 정확도 향상
- 실험 결과 4개의 데이터셋에서 우수한 예측 성능 및 효율성을 보임

감사합니다.